



杭州电子科技大学
HANGZHOU DIANZI UNIVERSITY

新禾屯育 养力崇策



机器学习 & 深度学习

支撑向量机 SVM

高飞 Fei Gao


gaofei@hdu.edu.cn

目录


- 间隔与支持向量
- 对偶问题
- 核函数
- 软间隔与正则化
- 支持向量回归
- 核方法




线性模型：在样本空间中寻找一个超平面，将不同类别的样本分开。



-Q: 将训练样本分开的超平面可能有很多, 哪一个好呢?




-Q:将训练样本分开的超平面可能有很多, 哪一个好呢?



- A:应选择“正中间”, 容忍性好, 鲁棒性高, 泛化能力最强.


超平面方程:

$$w^T x + b = 0$$



- 最大间隔: 寻找参数 w 和 b , 使得 γ 最大.

$$\begin{aligned} \arg \max_{w, b} \quad & \frac{2}{\|w\|} \\ \text{s.t.} \quad & y_i(w^\top x_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$




- 最大间隔: 寻找参数 \mathbf{w} 和 b , 使得 γ 最大.

$$\begin{aligned} \arg \max_{\mathbf{w}, b} \quad & \frac{2}{\|\mathbf{w}\|} \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$



$$\begin{aligned} \arg \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$



对偶问题

- 拉格朗日乘子法
 - 第一步：引入拉格朗日乘子 $\alpha_i \geq 0$ 得到拉格朗日函数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i (y_i (\mathbf{w}^\top \mathbf{x}_i + b) - 1)$$

- 拉格朗日乘子法

- 第一步：引入拉格朗日乘子 $\alpha_i \geq 0$ 得到拉格朗日函数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i (y_i (\mathbf{w}^\top \mathbf{x}_i + b) - 1)$$

- 第二步：令 $L(\mathbf{w}, b, \boldsymbol{\alpha})$ 对 \mathbf{w} 和 b 的偏导为零可得

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^m \alpha_i y_i = 0.$$

- 拉格朗日乘子法

- 第一步：引入拉格朗日乘子 $\alpha_i \geq 0$ 得到拉格朗日函数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i (y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1)$$

- 第二步：令 $L(\mathbf{w}, b, \boldsymbol{\alpha})$ 对 \mathbf{w} 和 b 的偏导为零可得

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i, \quad \sum_{i=1}^m \alpha_i y_i = 0.$$

- 第三步：回代

$$\begin{aligned} \min_{\boldsymbol{\alpha}} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

- 最终模型:

$$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^\top \mathbf{x} + b$$

- KKT条件:

$$\begin{cases} \alpha_i \geq 0, \\ y_i f(\mathbf{x}_i) \geq 1, \\ \alpha_i (y_i f(\mathbf{x}_i) - 1) = 0. \end{cases}$$

- 最终模型:

$$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^\top \mathbf{x} + b$$

- KKT条件:

$$\begin{cases} \alpha_i \geq 0, \\ y_i f(\mathbf{x}_i) \geq 1, \\ \alpha_i (y_i f(\mathbf{x}_i) - 1) = 0. \end{cases}$$

$$y_i f(\mathbf{x}_i) > 1 \quad \Rightarrow \quad \alpha_i = 0$$

支持向量机解的稀疏性

训练完成后, 大部分的训练样本都不需保留, 最终模型仅与支持向量有关.

- 基本思路：不断执行如下两个步骤直至收敛。

- 第一步：选取一对需更新的变量 α_i 和 α_j 。
 - 第二步：固定 α_i 和 α_j 以外的参数, 求解对偶问题更新 α_i 和 α_j 。

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

- 仅考虑 α_i 和 α_j 时, 对偶问题的约束变为

$$\alpha_i y_i + \alpha_j y_j = - \sum_{k \neq i, j} \alpha_k y_k, \quad \alpha_i \geq 0, \quad \alpha_j \geq 0.$$


$$\left\{ \begin{array}{l} \alpha_i \geq 0, \\ y_i f(\mathbf{x}_i) \geq 1, \\ \alpha_i (y_i f(\mathbf{x}_i) - 1) = 0. \end{array} \right.$$

用一个变量表示另一个变量, 回代入对偶问题可得一个单变量的二次规划, 该问题具有闭式解.

- 偏移项 b : 通过支持向量来确定.

核函数

- Q:若不存在一个能正确划分两类样本的超平面, 怎么办?
- A:将样本从原始空间映射到一个更高维的特征空间, 使得样本在这个特征空间内线性可分.



- 设样本 \mathbf{x} 映射后的向量为 $\phi(\mathbf{x})$, 划分超平面为 $f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b$

原始问题

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b) \geq 1, \quad i = 1, 2, \dots, m. \end{aligned}$$

对偶问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

只以内积的形式出现

预测

$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m \alpha_i y_i \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}) + b$$

- 基本想法：不显式地设计核映射, 而是设计核函数.

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$$

- 基本想法：不显式地设计核映射, 而是设计核函数.

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$$

- Mercer定理(充分非必要): 只要一个对称函数所对应的核矩阵半正定, 则它就能作为核函数来使用.

- 基本想法：不显式地设计核映射, 而是设计核函数.

$$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$$

- Mercer定理(充分非必要): 只要一个对称函数所对应的核矩阵半正定, 则它就能作为核函数来使用.
- 常用核函数:

名称	表达式	参数
线性核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$	
多项式核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j)^d$	$d \geq 1$ 为多项式的次数
高斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ ^2}{2\delta^2}\right)$	$\delta > 0$ 为高斯核的带宽(width)
拉普拉斯核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\ \mathbf{x}_i - \mathbf{x}_j\ }{\delta}\right)$	$\delta > 0$
Sigmoid核	$\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^\top \mathbf{x}_j + \theta)$	\tanh 为双曲正切函数, $\beta > 0, \theta < 0$








图 7: 核函数映射示意

《支持向量机通俗导论：理解SVM的三层境界》



<http://scikit-learn.org/stable/modules/svm.html>

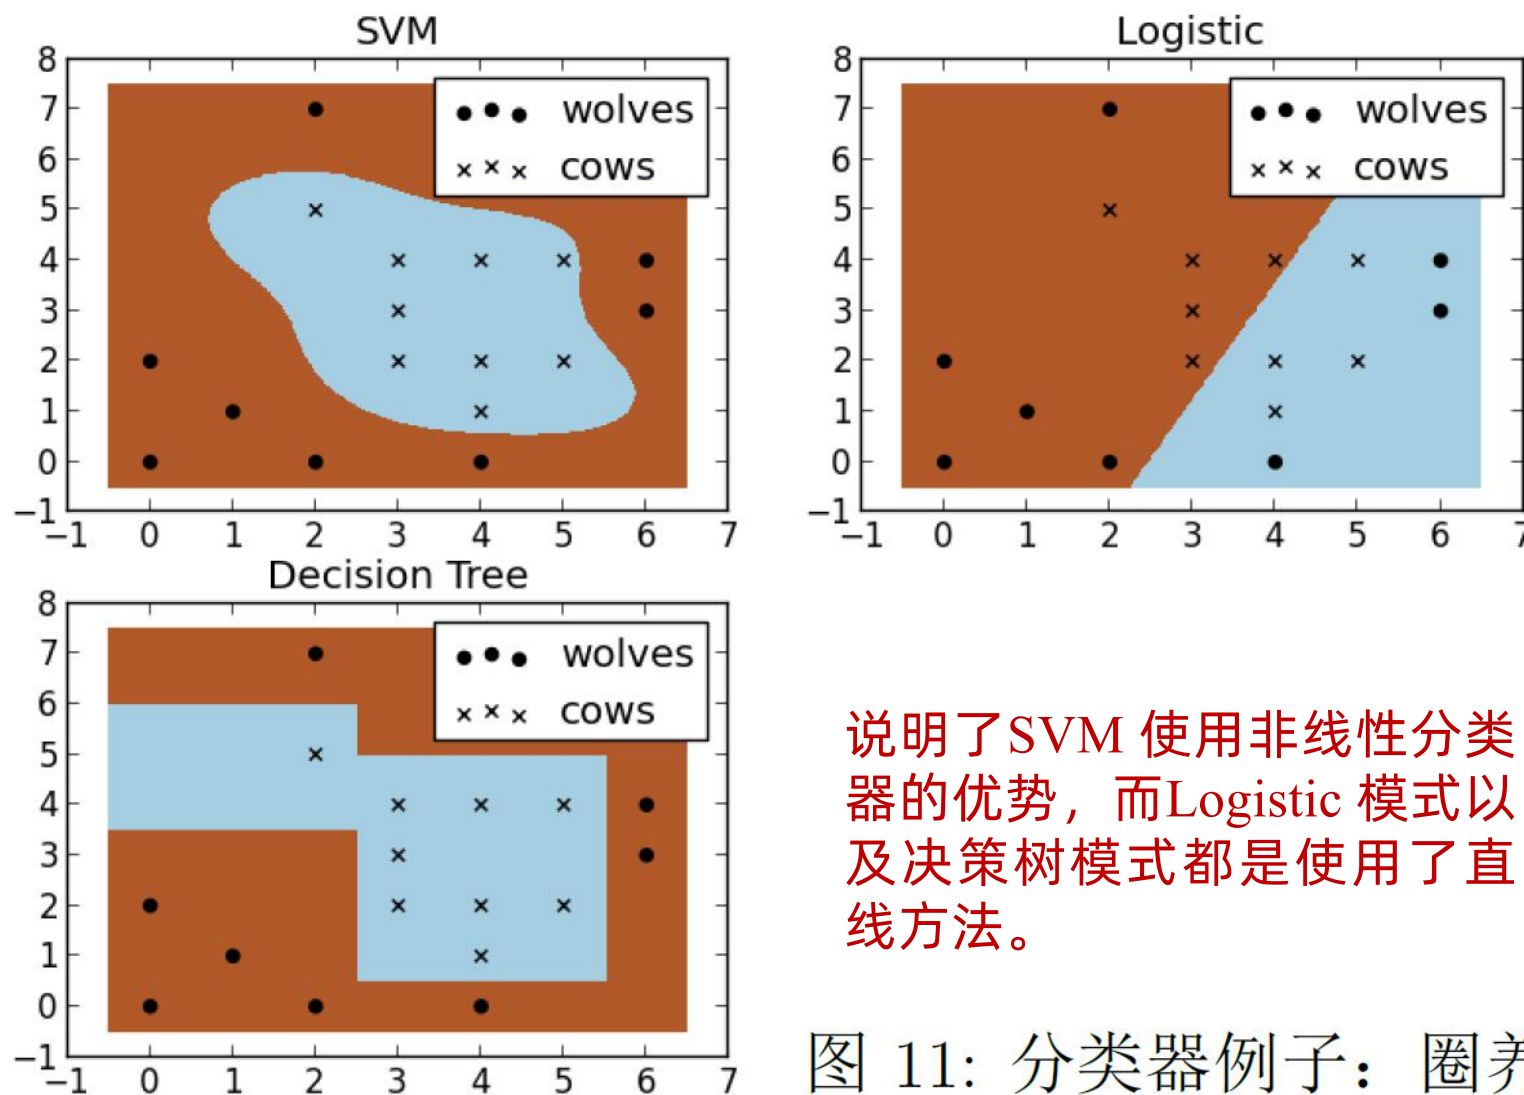


图 11: 分类器例子: 圈养


软间隔与正则化

• Q:

- 现实中, 很难确定合适的核函数使得训练样本在特征空间中线性可分;
- 同时一个线性可分的结果也很难断定是否是有过拟合造成的.

• A: 引入“软间隔”的概念,

- 允许支持向量机在一些样本上不满足约束.



- 基本想法：最大化间隔的同时, 让不满足约束的样本应尽可能少.


$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m l_{0/1} (y_i (\mathbf{w}^\top \phi(\mathbf{x}_i) + b) - 1)$$

其中 $l_{0/1}$ 是“0/1损失函数”

$$l_{0/1} = \begin{cases} 1 & z < 0 \\ 0 & otherwise \end{cases}$$

- 存在的问题：0/1损失函数非凸、非连续, 不易优化!


软间隔SVM



替代损失函数数学性质较好, 一般是0/1损失函数的上界


- 原始问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m. \end{aligned}$$



- 原始问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) - \sum_{i=1}^m \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^m \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, m. \end{aligned}$$



- 对偶问题

$$\min_{\mathbf{w}, b} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i(\mathbf{w}^\top \phi(\mathbf{x}_i) + b))$$

根据KKT条件可推得最终模型仅与支持向量有关, 也即 Hinge损失函数依然保持了支持向量机解的稀疏性.

- 支持向量机学习模型的更一般形式

$$\min_f \Omega(f) + C \sum_{i=1}^m l(f(\mathbf{x}_i), y_i)$$



结构风险, 描述模型的
某些性质




经验风险, 描述模型与
训练数据的契合程度


- 通过替换上面两个部分, 可以得到许多其他学习模型
 - 对数几率回归(Logistic Regression)
 - 最小绝对收缩选择算子(LASSO)
 -

支持向量回归

- 特点: 允许模型输出和实际输出间存在 2ϵ 的偏差.



- 落入中间 2ϵ 间隔带的样本不计算损失, 从而使得模型获得稀疏性.



- 原始问题

$$\begin{aligned} \min_{\mathbf{w}, b, \xi_i, \hat{\xi}_i} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m (\xi_i + \hat{\xi}_i) \\ \text{s.t.} \quad & y_i - \mathbf{w}^\top \phi(\mathbf{x}_i) - b \leq \epsilon + \xi_i, \\ & y_i - \mathbf{w}^\top \phi(\mathbf{x}_i) - b \geq -\epsilon - \hat{\xi}_i, \\ & \xi_i \geq 0, \hat{\xi}_i \geq 0, \quad i = 1, 2, \dots, m. \end{aligned}$$

- 对偶问题



$$\begin{aligned} \min_{\alpha, \hat{\alpha}} \quad & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m (\alpha_i - \hat{\alpha}_i)(\alpha_j - \hat{\alpha}_j) \kappa(\mathbf{x}_i, \mathbf{x}_j) + \sum_{i=1}^m (\alpha_i(\epsilon - y_i) + \hat{\alpha}_i(\epsilon + y_i)) \\ \text{s.t.} \quad & \sum_{i=1}^m (\alpha_i - \hat{\alpha}_i) = 0, \\ & 0 \leq \alpha_i \leq C, \quad 0 \leq \hat{\alpha}_i \leq C. \end{aligned}$$

- 预测


$$f(\mathbf{x}) = \mathbf{w}^\top \phi(\mathbf{x}) + b = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) y_i \kappa(\mathbf{x}_i, \mathbf{x}) + b$$

总结

- 支持向量机的“最大间隔”思想
- 对偶问题及其解的稀疏性
- 通过向高维空间映射解决线性不可分的问题
- 引入“软间隔”缓解特征空间中线性不可分的问题
- 将支持向量的思想应用到回归问题上得到支持向量回归
- 将核方法推广到其他学习模型




- LIBSVM
<http://www.csie.ntu.edu.tw/~cjlin/libsvm/>
- LIBLINEAR
<http://www.csie.ntu.edu.tw/~cjlin/liblinear/>
- SVM^{light}、SVM^{perf}、SVM^{struct}
http://svmlight.joachims.org/svm_struct.html
- Pegasos
<http://www.cs.huji.ac.il/~shais/code/index.html>
- 附：在线的jupyter notebook环境
<https://www.cocalc.com/app>



- FashionMNIST 是一个替代 MNIST 手写数字集 [1] 的图像数据集。
 - 由 Zalando（一家德国的时尚科技公司）旗下的研究部门提供。
 - 其涵盖了来自 10 种类别的共 7 万个不同商品的正面图片。
- FashionMNIST
 - 大小、格式和训练集/测试集划分与原始的 MNIST 完全一致。
 - 60000/10000 的训练测试数据划分，
 - 28x28 的灰度图片。

Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. Han Xiao, Kashif Rasul, Roland Vollgraf. arXiv: TBA



FashionMNIST

- 数据可视化
 - t-SNE



<https://zhuanlan.zhihu.com/p/28841880>

FashionMNIST

- 数据可视化

- t-SNE:
- Fashion-MNIST



<https://zhuanlan.zhihu.com/p/28841880>


FashionMNIST

- 数据可视化
 - t-SNE:
 - Fashion-MNIST
 - 局部放大



	Benchmark	Fashion MNIST	Original MNIST	Side-by-Side	Repository
Filter 129 results by Name, Parameter					
Name	Parameter	Accuracy (mean)			
SVC	{"C":100,"kernel":"sigmoid"}	0.703			
SVC	{"C":100,"kernel":"linear"}	0.833			
SVC	{"C":1,"kernel":"poly"}	0.874			
SVC	{"C":1,"kernel":"linear"}	0.841			
SVC	{"C":1,"kernel":"sigmoid"}	0.712			
SVC	{"C":10,"kernel":"sigmoid"}	0.703			
SVC	{"C":10,"kernel":"linear"}	0.836			
SVC	{"C":1,"kernel":"rbf"}	0.884			
SVC	{"C":10,"kernel":"rbf"}	0.896			
SVC	{"C":100,"kernel":"rbf"}	0.893			
SVC	{"C":10,"kernel":"poly"}	0.897			
SVC	{"C":100,"kernel":"poly"}	0.896			

<http://fashion-mnist.s3-website.eu-central-1.amazonaws.com/#>

 Benchmark Fashion MNIST Original MNIST Side-by-Side Repository		
Filter 129 results by Name, Parameter		
Name	Parameter	Accuracy (mean)
SVC	{"C":1,"kernel":"poly"}	0.957
SVC	{"C":1,"kernel":"linear"}	0.929
SVC	{"C":10,"kernel":"rbf"}	0.973
SVC	{"C":100,"kernel":"poly"}	0.978
SVC	{"C":10,"kernel":"sigmoid"}	0.873
SVC	{"C":1,"kernel":"rbf"}	0.966
SVC	{"C":10,"kernel":"linear"}	0.927
SVC	{"C":100,"kernel":"linear"}	0.926
SVC	{"C":100,"kernel":"rbf"}	0.972
SVC	{"C":100,"kernel":"sigmoid"}	0.868
SVC	{"C":1,"kernel":"sigmoid"}	0.898
SVC	{"C":10,"kernel":"poly"}	0.976

<http://fashion-mnist.s3-website.eu-central-1.amazonaws.com/#>



机器学习 & 深度学习



杭州电子科技大学
HANGZHOU DIANZI UNIVERSITY

新禾屯育 养力学习

- **FashionMNIST:**

- 10 种类别，共 7 万个图片，训练集/测试集划分：6：1
- 28x28 的灰度图片


- **实验设置：（采用FashionMNIST子集）**

- 10种类别；
- 每个类别随机选择700个图片；
- 训练集/测试集划分：6000/1000；
- 输入为图片灰度值（或梯度方向直方图等图像特征）；
- 分类器为SVM（也推荐测试线性分类器、决策树）；

- **测试分类方法数目 \geq 小组成员数/3**

- 统计在测试集上的分类精度；
- 分析不同参数设置对于性能的影响；

- **提交代码及技术报告，择优进行PPT报告；截止日期：2021年12月12日。**



<http://scikit-learn.org/>